

Análise de Cliques em Grafos de Coocorrência de Redações do ENEM

Amanda de Moura

221022220

Anna Clara C. E. Brandão

222006534

Anna Julia A. S. Primo

232024509

Giovana Martins de Brito

231038081

Mariana Martins Silva

222025932

Descrição do Problema

"Existem diferenças estruturais nos cliques de palavras dos grafos de coocorrência entre redações nota 1000 e redações de notas mais baixas do ENEM?"



Área de Aplicação

Educação / PLN



Foco da Análise

Estrutural e lexical - não temática



Fora do escopo

Classificação automática, PageRank, Dijkstra, comunidades

Dados

Grupo A - Nota 1000

64 redações

Fonte: Cartilhas INEP + Toda Matéria

- 1.015 sentenças processadas
- 12.560 lemas no total
- Vocabulário: 2.872 palavras únicas
- ~15,9 sentenças / redação

Grupo B - Abaixo de 1000

64 redações

Fonte: Repositório UOL (gpassero/uol-redacoes-xml)

- 608 sentenças processadas
- 6.536 lemas no total
- Vocabulário: 2.364 palavras únicas
- ~9,5 sentenças / redação

Grupos balanceados em número de redações para evitar distorções na comparação.

Pré-processamento - Pipeline spaCy

Carregamento

1

Modelo pt_core_news_sm; leitura do CSV com 128 redações

Segmentação

2

doc.sents - cada sentença é uma unidade de coocorrência

Lematização

3

token.lemma_ - "discutindo" -> "discutir"; "diversos" -> "diverso"

Filtragem POS

4

Mantém apenas NOUN, VERB, ADJ - descarta DET, ADP, PRON, PUNCT, NUM, AUX

Stopwords

5

Lista padrão spaCy PT + customizada ("texto", "redação", "tema", "forma"...)

Normalização

6

Lowercase em todos os lemas

Modelagem do Grafo de Coocorrência

Vértice

Um lema único (palavra de conteúdo pós-filtragem)

Aresta

Existe entre dois lemas que coocorrem na mesma sentença em ao menos um documento

Peso

Nº de sentenças (no corpus do grupo) em que os dois lemas coocorrem

Estrutura

Lista de adjacência: `dict[str, dict[str, int]]` - acesso $O(1)$ por ser tabela hash

Por que Lista de Adjacência?

- Grafo esparso: cada palavra se conecta a ~11 outras (de 2.872 possíveis)
- Matriz exigiria 8,2 milhões de células (>99% zeros)
- Adição de vértice: $O(1)$ vs $O(V^2)$ na matriz
- BFS e cliques acessam vizinhos diretamente

Podas aplicadas

- Absoluta: Remove arestas com peso < 2
- Relativa: Remove vértices com grau muito baixo
- Pontes: Remove arestas-ponte (via BFS)

Algoritmos - Implementados do Zero

Fila (FIFO)

$O(1)$

- Nós encadeados: enfileirar / desenfileirar em $O(1)$
- Suporte ao BFS

BFS

$O(V+E)$

- `bfs_niveis()`: distância lexical a partir de palavra-semente
- `componentes_conexos()`: coesão vs. fragmentação do vocabulário
- `bfs()`: detecção de pontes para poda do grafo

Cliques (DFS)

$O(3^{(V/3)})^*$

- **DFS** com verificação *eh_clique* (algoritmo do slide de aula)
- Ordenação lexicográfica para evitar duplicatas
- `filtrar_maximais()` remove subconjuntos não-maximais
- `MIN_PESO_ARESTA = 2` | `TAMANHO_MINIMO = 4`

* Complexidade da enumeração de cliques maximais - inerente ao problema (NP-difícil). Podas reduzem drasticamente o espaço de busca.

Implementação - Estrutura do Código

`preprocessing.py`

R2

Pipeline spaCy: tokenização, lematização, filtragem POS, stopwords -> JSONs

`bfs.py`

R3

BFS por níveis, componentes conexos e detecção de pontes

`fila.py`

R3

Fila FIFO com nós encadeados - enfileirar / desenfileirar em $O(1)$

`cliques.py`

R4

DFS + eh_clique (slide) + filtrar_maximais + relatório comparativo

`grafo.py/graph.py`

R3


Duas interfaces de grafo; graph.py é o principal do pipeline

`analise.py`

R5

Métricas comparativas e geração de gráficos

Exemplos de Entrada e Saída



Exemplo real do Grupo A (nota 1000). Todas as 4 palavras coocorrem entre si em pelo menos 2 sentenças - formam um clique maximal.

Resultados - Pipeline de Podas

Objetivo: Redução drástica do ruído e otimização computacional para busca de cliques maximais.

```
=====
EXECUÇÃO DE MÉTRICAS GLOBAIS: Grupo A (Nota 1000)
=====

--> Aplicando Pipeline de Podas:
[bruto] vértices=2872 arestas=72350
[poda_absoluta] vértices=1390 arestas=10236
[poda_relativa] vértices=74 arestas=173
[poda_pontes] vértices=45 arestas=148

=====
EXECUÇÃO DE MÉTRICAS GLOBAIS: Grupo B (Abaixo de 1000)
=====

--> Aplicando Pipeline de Podas:
[bruto] vértices=2364 arestas=35372
[poda_absoluta] vértices=1201 arestas=4012
[poda_relativa] vértices=409 arestas=866
[poda_pontes] vértices=219 arestas=679
```

```
def aplicar_podas(grafo, min_peso=2, fator_media=0.4, fator_max=0.12, usar_pontes=True):
    log = []

    def registrar(etapa, g):
        stats = estatisticas_grafo(g)
        log.append({"etapa": etapa, **stats})
        print(f"[{etapa}] vértices={stats['vertices']} arestas={stats['arestas']}")
        return g

    g = registrar("bruto", grafo)
    g = registrar("poda_absoluta", poda_peso_absoluto(g, min_peso))
    g = registrar("poda_relativa", poda_peso_relativo(g, fator_media, fator_max))
    if usar_pontes:
        g = registrar("poda_pontes", poda_pontes(g))
    return g, log
```

Resultados - Análise Comparativa

Eficiência Léxica: Grupo A atinge coesão máxima com apenas 45 vértices, enquanto o Grupo B permanece inflado com 219 vértices.




TABELA COMPARATIVA DE RESULTADOS GLOBAIS (R5)		
Métrica Medida	Grupo A	Grupo B
Nº Total de Cliques (>= 4)	30	96
Tamanho Médio dos Cliques	4.63	4.3
Tamanho do Maior Clique	7	6
Nº de Componentes Conexos	1	1
Vértices Restantes (Pós-Poda)	45	219
Arestas Restantes (Pós-Poda)	148	679

Métricas previstas: Nº de cliques / tamanho médio/máximo / componentes conexos / vértices pós-poda / arestas pós-poda

Resultados - Enumeração de Cliques

Grupo A - Vocabulário Coeso

Redações nota 1000 que concentram-se em torno de 30 cliques em eixos temáticos consolidados (Saúde Mental e Cinema). Vocabulário especializado e consistente.

Grupo B - Maior Dispersão

Redações com notas abaixo de 1000 concentram-se em torno de 96 cliques em temas variados (fórmulas coringas de política, sociedade e corrupção). Maior dispersão e menor coesão lexical.

Resultados - Densidade e Métricas Globais

Densidade Argumentativa: O Grupo B acumula 96 cliques curtos e rasos, enquanto o Grupo A foca em 30 estruturas altamente densas e completas.




TABELA COMPARATIVA DE RESULTADOS GLOBAIS (R5)		
Métrica Medida	Grupo A	Grupo B
Nº Total de Cliques (>= 4)	30	96
Tamanho Médio dos Cliques	4.63	4.3
Tamanho do Maior Clique	7	6
Nº de Componentes Conexos	1	1
Vértices Restantes (Pós-Poda)	45	219
Arestas Restantes (Pós-Poda)	148	679

Resultados - Análise Qualitativa dos Cliques

--> Mapeamento dos Cliques:

[Grupo A - Nota 1000] - 30/30 Cliques:

1. Tamanho 7: ['brasileiro', 'doença', 'estigma', 'mental', 'pessoa', 'social', 'sociedade']
2. Tamanho 6: ['acesso', 'cidadão', 'direito', 'indivíduo', 'registro', 'social']
3. Tamanho 6: ['acesso', 'brasileiro', 'cidadão', 'direito', 'registro', 'social']
4. Tamanho 6: ['associar', 'brasileiro', 'doença', 'estigma', 'mental', 'sociedade']
5. Tamanho 6: ['acesso', 'brasileiro', 'cinema', 'população', 'social', 'sociedade']
6. Tamanho 5: ['brasileiro', 'mental', 'população', 'social', 'sociedade']
7. Tamanho 5: ['acesso', 'brasileiro', 'pessoa', 'social', 'sociedade']
8. Tamanho 5: ['acesso', 'brasileiro', 'civil', 'registro', 'social']
9. Tamanho 5: ['brasileiro', 'comunidade', 'país', 'povo', 'tradicional']
10. Tamanho 5: ['brasileiro', 'comunidade', 'povo', 'social', 'tradicional']

Foco Temático: Conexões longas atacam diretamente os temas oficiais do INEP.

[Grupo B - Nota < 1000] - 30/96 Cliques:

1. Tamanho 6: ['brasileiro', 'haver', 'país', 'político', 'população', 'público']
2. Tamanho 6: ['brasileiro', 'haver', 'político', 'população', 'público', 'sociedade']
3. Tamanho 6: ['ato', 'brasileiro', 'corrupção', 'fato', 'população', 'sociedade']
4. Tamanho 6: ['ato', 'caráter', 'injustiça', 'pessoa', 'praticar', 'violência']
5. Tamanho 6: ['haver', 'país', 'político', 'população', 'público', 'uso']
6. Tamanho 5: ['político', 'população', 'social', 'sociedade', 'ter']
7. Tamanho 5: ['pessoa', 'população', 'social', 'tecnologia', 'ter']
8. Tamanho 5: ['brasileiro', 'haver', 'país', 'pessoa', 'população']
9. Tamanho 5: ['acabar', 'brasileiro', 'fato', 'pessoa', 'população']
10. Tamanho 5: ['ato', 'brasileiro', 'fato', 'pessoa', 'população']

Dependência de Clichês: Uso crônico de repertórios 'coringas' e vagos sobre política e sociedade para preencher o texto.

Análise Comparativa dos Resultados

1

Descoberta 1

Precisão Temática

2

Descoberta 2

Esvaziamento Semântico

3

Descoberta 3

Raio Semântico

Análise Comparativa - Precisão Temática vs. Receita de Bolo

Grupo A - Nota 1000

Cliques temáticos precisos

Tema 2020 — Estigma associado às doenças mentais

doença · estigma · mental

Tema 2021 — Invisibilidade e registro civil

cidadão · direito · registro

Tema 2019 — Democratização do cinema

acesso · cinema

Vocabulário direcionado ao tema — rede densa e precisa.

Grupo B - Abaixo de 1000

*Cliques genéricos
(texto coringa)*

corrupção · político · população

ato · injustiça · violência

O algoritmo detectou o padrão texto coringa:
modelos genéricos de reclamação social sem foco
no tema específico da proposta.

Termos servem para qualquer tema — baixa coesão temática.

A "Pobreza" de Vocabulário — Esvaziamento Semântico

Grupo A - Nota 1000

Substantivos abstratos não comuns

Grupo A

Substantivos abstratos rebuscados

Quase sem verbos nos maiores cliques.

A rede é sustentada por substantivos abstratos:

acesso

cidadania

direito

invisibilidade

valorização

preconceito

Alta capacidade de abstração e domínio da língua portuguesa.

A ausência de verbos/substantivos fracos é indicativo de coesão.

Grupo B - Abaixo de 1000

*Cliques genéricos
(texto coringa)*

Grupo B

Verbos fracos e substantivos vazios

Cliques cheios de verbos fracos/vazios:

haver

ter

fazer

acabar

achar

ver

tomar

Além disso, substantivos de baixo valor semântico:

ato

fato

Coesão fragilizada pelo distanciamento lexical.

O Raio Semântico da Redação

7

Grupo A
Clique máximo

conceitos conectados
em uma única sentença

Os 7 conceitos do clique fora do genérico:

brasileiro · doença · estigma · mental ·
pessoa · social · sociedade

Na mesma sentença, o candidato conectou todos esses conceitos de forma lógica e sintática — demonstrando alta coesão e raio semântico fora da média.

6

Grupo B
Clique máximo

menor e formado por palavras
repetitivas e redundantes

Problema identificado:

Tamanho menor e termos sem variação — repetições que **simulam coesão** sem produzi-la.

A redundância nos cliques do Grupo B indica ausência de articulação entre conceitos distintos — a sentença não avança semanticamente.

Conclusão: O que o trabalho revelou sobre a diferença entre redações nota 1000 e as abaixo de 1000?

Descoberta 1 — Precisão Temática

Grupo A usa vocabulário mapeado aos temas reais das provas. Grupo B usa termos genéricos que servem para qualquer argumento.

Descoberta 2 — Esvaziamento Semântico

Grupo A sustenta seus cliques com substantivos abstratos ricos. Grupo B enche os cliques de verbos fracos e substantivos de baixo valor.

Descoberta 3 — Raio Semântico

Grupo A conecta 7 conceitos numa única sentença — coesão impecável. Grupo B atinge apenas 6, com redundâncias que simulam coesão sem produzi-la.

A análise de coocorrência foi útil para entender no que reflete redações com nota máxima que possuem coesão real diferenciando daquelas que apenas simulam domínio temático.

Transparência - Uso de LLM

Brainstorming de ideias

1

Ideias do que poderia ser feito com o tema que foi designado para o nosso grupo, qual poderia ser o domínio, até conseguirmos definir uma pergunta que poderia ser respondida.

Melhor compreensão sobre a análise de coocorrência para o nosso objetivo

3

Definição do problema escopo pronto utilizamos a IA para ajudar a entender como de fato poderia ser implementado esta análise, alinhado com o domínio e os dados a serem coletados.

Explicação do papel dos algoritmos alinhado ao objetivo do tema

5

Mais voltado para significado e importância e impacto, aqui foi utilizada a IA para nos ajudar a entender como os conceitos que aprendemos em sala de aula poderia ser implementados e qual era a relevância do papel dele no trabalho.

Refinamento do objetivo do trabalho

2

Após um domínio melhor definido utilizamos a IA para no ajudar no escopo do nosso trabalho definindo melhor o que seria e o que não seria.

Visão do trabalho em relação ao propósito do tema

4

Foi utilizada a IA para entendermos, do ponto inicial da coleta até a implementação dos algoritmos, quais seriam as conclusões finais que poderíamos ter e que fossem de fato relevantes para o domínio.

Planejamento & Estruturação

6

Definição de etapas e entregáveis para melhor organização do grupo em relação a divisão de tarefas para poder ser desenvolvido em tempo ábil. Além de também ter ajudado na organização e estruturação das pastas do projeto.

Obrigada pela atenção!

Amanda de Moura

221022220

Anna Clara C. E. Brandão

222006534

Anna Julia A. S. Primo

232024509

Giovana Martins de Brito

231038081

Mariana Martins Silva

222025932